
Линейная алгебра для Data Science

Аналитические и вычислительные задания

Содержание

Назначение работы	1
Как работать с материалом	1
Единая канва	1
Общий набор данных	1
1. Векторы: координаты, длина, угол и ортогональность	2
Короткая теория	2
Задание 1.1. Координаты и длина	2
Задание 1.2. Угол между векторами	4
Задание 1.3. Ортогональность	4
Задание 1.4. Векторы объектов в данных	4
2. Матрица данных и матричные операции	4
Короткая теория	4
Задание 2.1. Сложение матриц	4
Задание 2.2. Линейная комбинация матриц	5
Задание 2.3. Произведение матриц и порядок множителей	5
Задание 2.4. Размерность матрицы данных	5
3. Линейные отображения	6
Короткая теория	6
Задание 3.1. Матрица преобразования	7
Задание 3.2. Образ вектора	7
4. Определитель и ранг: сохранена ли информация	7
Короткая теория	7
Задание 4.1. Определитель	7
Задание 4.2. Ранг двух матриц	8
5. Базис и координаты	8
Короткая теория	8
Задание 5.1. Проверка базиса	8
Задание 5.2. Координаты в новом базисе	8
6. Системы линейных уравнений	9
Короткая теория	9
Задание 6.1. Квадратная система	9
Задание 6.2. Недоопределённая система	9
7. Проекция	10
Короткая теория	10
Задание 7.1. Проекция на прямую	10
8. Метод наименьших квадратов: первая модель данных	10
Короткая теория	10
Задание 8.1. Матричная запись регрессии	10
Задание 8.2. Невязка и качество приближения	11
Задание 8.3. Регрессия как проекция	11
9. Базовое PCA: новое направление вместо двух признаков	11
Зачем это нужно	11
Задание 9.1. Выполнить готовый алгоритм	13
Задание 9.2. Польза и ограничения	13

10. Базовое SVD: малоранговое приближение изображения	13
Зачем это нужно	13
Задание 10.1. Выполнить готовое SVD	13
Задание 10.2. Связь PCA и SVD	14
11. Итоговая интерпретация	14
Задание 11.1. Карта понятий	14
Что сдавать	14
Справка по синтаксису	15

Назначение работы

Эта лабораторная работа связывает базовые операции линейной алгебры с тем, как данные представлены и обрабатываются в Data Science. Сначала каждое действие выполняется аналитически, затем записывается математически в Markdown и только после этого проверяется с помощью NumPy. В заключительной части готовый код показывает базовую идею метода главных компонент (РСА) и сингулярного разложения (SVD): от студента требуется не программировать эти алгоритмы с нуля, а понимать входные данные, читать результат и объяснять его пользу.

Работа рассчитана на интенсивное занятие с обязательным домашним продолжением. На занятии следует пройти материал до раздела 8 включительно. Если какая-либо из предшествующих задач не завершена в аудитории, она также входит в домашнюю часть. Разделы 9 и 10 обязательны для самостоятельного завершения.

Основной источник теории — пособие «**Линейная алгебра**». Из «**Высшей математики. Практикума**» взята только часть стартовых аналитических условий. Остальные аналитические вопросы, задачи на общем наборе данных и вычислительные исследования специально составлены для этой работы по материалам пособия. Поэтому отсутствие ссылки на практикум означает не пропуск источника, а авторское задание внутри общей канвы.

Как работать с материалом

Каждый этап помечен способом работы:

- **[Бумага]** — решить аналитически без NumPy;
- **[Markdown]** — перенести ход решения в Markdown-ячейку ноутбука, используя LaTeX;
- **[Python]** — проверить вычисления или выполнить готовый вычислительный фрагмент;
- **[Интерпретация]** — объяснить результат обычными словами применительно к данным.

Ответ считается полным, если виден не только итог, но и ход рассуждения: исходные объекты, используемое правило, промежуточные вычисления, проверка и смысл результата. Десятичное число не заменяет точное значение, если ответ естественно выражается дробью, корнем или углом.

Единая канва

Мы будем двигаться по одной цепочке:

1. вектор описывает один объект;
2. норма и скалярное произведение сравнивают векторы;
3. матрица собирает много объектов в набор данных;
4. матричные операции преобразуют этот набор;
5. линейное отображение переводит признаки в новое представление;
6. определитель и ранг показывают, не потеряна ли информация;
7. система уравнений восстанавливает неизвестные параметры;
8. метод наименьших квадратов даёт лучшее приближённое решение, если точного нет;
9. РСА оставляет наиболее информативные направления;
10. SVD строит малоранговые приближения и позволяет оценить компромисс между точностью и объёмом хранения.

Общий набор данных

Во всех вычислительных разделах используются сведения об учебной активности восьми студентов. Строка соответствует студенту, первый столбец — числу часов практики за условный период, второй — числу выполненных комплектов упражнений, а отдельный вектор y содержит итоговый балл.

Студент	Часы практики	Комплекты упражнений	Итоговый балл
Аня	1	2	48
Борис	2	2	52

Студент	Часы практики	Комплекты упражнений	Итоговый балл
Вера	2	3	55
Глеб	3	4	63
Дина	4	5	70
Егор	5	7	78
Жанна	6	8	85
Илья	7	10	94

Матрица признаков и вектор результата имеют вид

$$\mathbf{X} = \begin{pmatrix} 1 & 2 \\ 2 & 2 \\ 2 & 3 \\ 3 & 4 \\ 4 & 5 \\ 5 & 7 \\ 6 & 8 \\ 7 & 10 \end{pmatrix} \in \mathbb{R}^{8 \times 2}, \quad \mathbf{y} = \begin{pmatrix} 48 \\ 52 \\ 55 \\ 63 \\ 70 \\ 78 \\ 85 \\ 94 \end{pmatrix} \in \mathbb{R}^8.$$

Набор специально мал: все существенные действия можно понять вручную, а затем увидеть тот же язык линейной алгебры в коде.

1. Векторы: координаты, длина, угол и ортогональность

Короткая теория

Вектор-столбец из n действительных чисел обозначается $\mathbf{x} \in \mathbb{R}^n$. Его евклидова норма и скалярное произведение задаются формулами

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}, \quad \langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = \sum_{i=1}^n x_i y_i.$$

Если оба вектора ненулевые, угол φ между ними определяется равенством

$$\cos \varphi = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}.$$

При $\langle \mathbf{x}, \mathbf{y} \rangle = 0$ векторы ортогональны. См. **обозначения векторов, с. 4, нормы, с. 8 и скалярное произведение и угол, с. 14–15.**

Задание 1.1. Координаты и длина

Источник условия: **практикум, с. 40, задача 3.**

Даны точки $A(1, 2, 3)$ и $B(3, -4, 6)$. Найдите координаты вектора $\overrightarrow{AB}$ и его длину.

- **[Бумага]** Запишите правило $\overrightarrow{AB} = B - A$, выполните вычитание по координатам и вычислите норму.
- **[Markdown]** Перенесите полную выкладку, сохранив точное значение нормы.
- **[Python]** Создайте массивы A и B , затем проверьте результат с помощью вычитания и `np.linalg.norm`.
- **[Интерпретация]** Объясните, что означает направление $A \rightarrow B$ и почему длина не может быть отрицательной.




Рис. 1. Представление чисел в виде вектора, матрицы и тензора. Подробная подпись приведена в теоретическом пособии на с. 5.




Рис. 2. Сложение, умножение на скаляр и представление вектора в разных базисах.

Задание 1.2. Угол между векторами

Источник условия: [практикум, с. 39, задача 1.](#)

Найдите угол между векторами

$$\mathbf{a} = (-1, 1, 0)^T, \quad \mathbf{b} = (1, -2, 2)^T.$$

- **[Бумага]** Найдите скалярное произведение, обе нормы, $\cos \varphi$ и угол в градусах.
- **[Markdown]** Покажите подстановку в формулу, а не только значение угла.
- **[Python]** Проверьте вычисление через `np.dot`, `np.linalg.norm`, `np.clip`, `np.arccos` и `np.degrees`.
- **[Интерпретация]** По знаку скалярного произведения определите, является угол острым, прямым или тупым.

Задание 1.3. Ортогональность

Источник условия: [практикум, с. 39, задача 2.](#)

При каком значении x векторы

$$\mathbf{a} = (3, 2, -1)^T, \quad \mathbf{b} = (2, x, 2)^T$$

ортогональны?

- **[Бумага]** Приравняйте $\mathbf{a}^T \mathbf{b}$ к нулю и решите скалярное уравнение.
- **[Markdown]** Запишите проверку найденного значения подстановкой.
- **[Python]** Соберите вектор $\mathbf{b}$ с найденным x и вычислите $\mathbf{a} @ \mathbf{b}$.
- **[Интерпретация]** Объясните, почему нулевое скалярное произведение можно рассматривать как отсутствие линейной согласованности направлений.

Задание 1.4. Векторы объектов в данных

- **[Бумага]** Запишите векторы признаков Ани и Ильи из общей таблицы. Найдите вектор изменения от Ани к Илье и его норму.
- **[Markdown]** Укажите единицы каждой координаты и объясните, почему смешанная евклидова норма здесь требует осторожной интерпретации.
- **[Python]** Повторите расчёт для первой и последней строк $\mathbf{X}$.
- **[Интерпретация]** Ответьте, зачем перед сравнением признаков с разными единицами измерения выполняют стандартизацию. К этому вопросу мы вернёмся в PCA.

2. Матрица данных и матричные операции

Короткая теория

Матрица $\mathbf{A} \in \mathbb{R}^{m \times n}$ содержит m строк и n столбцов. В нашей договорённости строки — наблюдения, столбцы — признаки. Матрицы одинакового размера складываются поэлементно, а умножение на скаляр масштабирует каждый элемент. Теорию обозначений см. на [с. 4–5](#), а правила произведения матриц — на [с. 15–18](#).

Задание 2.1. Сложение матриц

Источник условия: [практикум, с. 18.](#)

Вычислите $\mathbf{A} + \mathbf{B}$, если

$$\mathbf{A} = \begin{pmatrix} 3 & 5 & 7 \\ 2 & -1 & 0 \\ 4 & 3 & 2 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 1 & 2 & 4 \\ 2 & 3 & -2 \\ -1 & 0 & 1 \end{pmatrix}.$$

- **[Бумага]** Выполните сложение поэлементно.




Рис. 3. Порядок обхода элементов по строкам и по столбцам. Для анализа данных особенно важно явно фиксировать, что обозначают оси массива.

- **[Markdown]** Покажите исходные матрицы и итоговую матрицу.
- **[Python]** Проверьте результат оператором `+`.
- **[Интерпретация]** Приведите пример, когда складывать две матрицы данных осмысленно, и пример, когда одинакового размера недостаточно из-за разного смысла столбцов.

Задание 2.2. Линейная комбинация матриц

Источник условия: [практикум, с. 18](#).

Вычислите $2A + 5B$, если

$$A = \begin{pmatrix} 3 & 5 \\ 4 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 2 & 3 \\ 1 & -2 \end{pmatrix}.$$

- **[Бумага]** Сначала умножьте каждую матрицу на её коэффициент, затем сложите.
- **[Markdown]** Сохраните один промежуточный шаг.
- **[Python]** Проверьте выражением `2 * A + 5 * B`.
- **[Интерпретация]** Объясните линейную комбинацию как взвешенное объединение двух источников числового сигнала.

Задание 2.3. Произведение матриц и порядок множителей

Источник условия: [практикум, с. 19](#).

Для матриц

$$A = \begin{pmatrix} 1 & 3 & 1 \\ 2 & 0 & 4 \\ 1 & 2 & 3 \end{pmatrix}, \quad B = \begin{pmatrix} 2 & 1 & 0 \\ 1 & -1 & 2 \\ 3 & 2 & 1 \end{pmatrix}$$

найдите AB и BA .

- **[Бумага]** Для элемента $(1, 1)$ каждого произведения явно покажите скалярное произведение строки и столбца. Затем заполните обе матрицы.
- **[Markdown]** Сопоставьте результаты и сформулируйте вывод о перестановочности.
- **[Python]** Проверьте оба произведения оператором `@` и сравните их через `np.array_equal`.
- **[Интерпретация]** Объясните, почему «сначала преобразование B , затем A » в общем случае отличается от обратного порядка.

Задание 2.4. Размерность матрицы данных

- **[Markdown]** Для $X \in \mathbb{R}^{8 \times 2}$ подпишите смысл числа 8 и числа 2. Для $y \in \mathbb{R}^8$ объясните соответствие элементов строкам X .
- **[Python]** Выведите `X.shape`, `y.shape`, средние значения столбцов и матрицу $X^T X$.
- **[Интерпретация]** Объясните, почему перестановка двух столбцов меняет смысл коэффициентов будущей модели, хотя число строк сохраняется.




Рис. 4. Элемент произведения получается скалярным произведением соответствующей строки и столбца.

3. Линейные отображения

Короткая теория

Линейное отображение в координатах записывается как

$$y = Ax.$$

Столбцы A показывают, куда переходят базисные векторы. Отображение сохраняет сложение и умножение на скаляр. См. [теорию](#), с. 7–8.




Рис. 5. Матрица переводит векторы области определения в образ; векторы ядра переходят в нулевой вектор.

Задание 3.1. Матрица преобразования

Источник условия: [практикум, с. 45, задача 1а](#).

Линейное преобразование задано правилом

$$A(\mathbf{x}) = \begin{pmatrix} x_2 - x_3 \\ x_1 \\ x_1 + x_3 \end{pmatrix}.$$

Найдите матрицу этого преобразования в стандартном базисе.

- **[Бумага]** Найдите $A(\mathbf{e}_1)$, $A(\mathbf{e}_2)$ и $A(\mathbf{e}_3)$ и поместите полученные векторы в столбцы.
- **[Markdown]** Проверьте полученную матрицу символическим умножением на $(x_1, x_2, x_3)^T$.
- **[Python]** Умножьте матрицу на несколько тестовых векторов и сопоставьте с исходным правилом.
- **[Интерпретация]** Объясните, почему каждый выходной признак является линейной комбинацией входных.

Задание 3.2. Образ вектора

Источник условия: [практикум, с. 46, задача 2а](#).

Найдите образ вектора $\mathbf{a} = (1, -2, 3)^T$ при отображении с матрицей

$$\mathbf{A} = \begin{pmatrix} 1 & -1 & 0 \\ 3 & 0 & 1 \\ 1 & 1 & -2 \end{pmatrix}.$$

- **[Бумага]** Вычислите $\mathbf{Aa}$ строка за строкой.
- **[Markdown]** Запишите произведение и итоговый вектор.
- **[Python]** Проверьте оператором `@`.
- **[Интерпретация]** Представьте, что $\mathbf{a}$ — три исходных признака, а строки $\mathbf{A}$ — правила создания трёх новых признаков. Расшифруйте первое правило словами.

4. Определитель и ранг: сохранена ли информация

Короткая теория

Определитель квадратной матрицы показывает коэффициент изменения ориентированного объёма при линейном отображении. Если $\det(\mathbf{A}) = 0$, матрица вырождена и обратной матрицы не существует. Ранг — размерность пространства, натянутого на строки или столбцы матрицы. Он показывает число линейно независимых направлений. См. [определитель, с. 10–11](#) и [ранг, с. 11–12](#).

Задание 4.1. Определитель

Источник условия: [практикум, с. 16, задача 1](#).

Вычислите

$$\det \begin{pmatrix} 5 & 2 & 3 \\ -4 & 3 & 5 \\ 2 & 3 & 4 \end{pmatrix}.$$

- **[Бумага]** Разложите определитель по первой строке и покажите три минора.
- **[Markdown]** Запишите полный расчёт со знаками алгебраических дополнений.
- **[Python]** Проверьте через `np.linalg.det`. Помните, что вычисление с плавающей точкой может дать число, очень близкое к целому.
- **[Интерпретация]** Сделайте вывод об обратимости и о том, схлопывает ли отображение трёхмерный объём.

Задание 4.2. Ранг двух матриц

Источник условий: **практикум, с. 25, задачи 1 и 2.**

Найдите ранги матриц

$$A_1 = \begin{pmatrix} 1 & 2 \\ 0 & 5 \\ -1 & 4 \\ 1 & 1 \end{pmatrix}, \quad A_2 = \begin{pmatrix} 3 & -5 & -1 & -2 \\ 8 & -6 & 3 & -7 \\ 2 & 4 & 5 & -3 \end{pmatrix}.$$

- **[Бумага]** Приведите каждую матрицу к ступенчатому виду элементарными преобразованиями строк. Число ненулевых строк даст ранг.
- **[Markdown]** Покажите ключевые преобразования, достаточные для проверки ответа.
- **[Python]** Сравните с `np.linalg.matrix_rank`.
- **[Интерпретация]** Для каждой матрицы назовите максимальное возможное значение ранга и объясните, означает ли найденный ранг линейную зависимость столбцов.

5. Базис и координаты

Короткая теория

Базис пространства — линейно независимая система векторов, через которую единственным образом выражается каждый вектор пространства. В $\mathbb{R}^3$ три вектора образуют базис тогда и только тогда, когда матрица из этих столбцов имеет ранг 3. См. **теорию, с. 6–7.**

Задание 5.1. Проверка базиса

Источник условия: **практикум, с. 43, задача 16.**

Проверьте, образуют ли базис в $\mathbb{R}^3$ векторы

$$\mathbf{a} = (0, 1, 2)^T, \quad \mathbf{b} = (1, 0, 1)^T, \quad \mathbf{c} = (-1, 2, 4)^T.$$

- **[Бумага]** Составьте матрицу из данных векторов-столбцов и проверьте её ранг или определитель.
- **[Markdown]** Сформулируйте вывод через линейную независимость.
- **[Python]** Проверьте ранг и определитель.
- **[Интерпретация]** Объясните, что потеряется, если три выбранных направления окажутся линейно зависимыми.

Задание 5.2. Координаты в новом базисе

Источник условия: **практикум, с. 43, задача 2а.**

Разложите $\mathbf{x} = (1, -4, 4)^T$ по векторам

$$\mathbf{p} = (2, 1, -1)^T, \quad \mathbf{r} = (1, -1, 1)^T, \quad \mathbf{q} = (0, 3, 2)^T.$$

- **[Бумага]** Введите коэффициенты α, β, γ в равенстве $\mathbf{x} = \alpha\mathbf{p} + \beta\mathbf{r} + \gamma\mathbf{q}$ и решите систему.
- **[Markdown]** Выполните обратную проверку линейной комбинацией.
- **[Python]** Решите матричное уравнение через `np.linalg.solve`.
- **[Интерпретация]** Объясните отличие самого геометрического вектора от его координат в выбранном базисе.

6. Системы линейных уравнений

Короткая теория

Система записывается компактно:

$$Ax = b.$$

Квадратная невырожденная матрица задаёт единственное решение. У недоопределённой системы неизвестных больше, чем независимых уравнений, поэтому обычно остаются свободные параметры. У переопределённой системы уравнений больше, чем неизвестных, и точного решения может не существовать. См. [теорию, с. 36–38](#).




Рис. 6. Недоопределённая, квадратная и переопределённая системы в геометрическом представлении.

Задание 6.1. Квадратная система

Источник условия: [практикум, с. 34, задача 3](#).

Решите методом Гаусса систему

$$\begin{cases} 2x - y + z = 2, \\ 3x + 2y + 2z = -2, \\ x - 2y + z = 1. \end{cases}$$

- **[Бумага]** Запишите расширенную матрицу, приведите её к ступенчатому виду и выполните обратный ход.
- **[Markdown]** Покажите элементарные преобразования строк и подстановку решения в исходные уравнения.
- **[Python]** Проверьте через `np.linalg.solve` и вычислите невязку $Ax - b$.
- **[Интерпретация]** Объясните, почему нулевой вектор невязки означает точное выполнение всех уравнений.

Задание 6.2. Недоопределённая система

Источник условия: [практикум, с. 34, задача 1](#).

Решите систему

$$\begin{cases} 3x_1 - 4x_2 + 6x_3 = -7, \\ 2x_1 + 5x_2 + 4x_3 = 12. \end{cases}$$

- **[Бумага]** Положите $x_3 = t$, выразите x_1 и x_2 через t и запишите всё семейство решений.
- **[Markdown]** Проверьте обе строки системы символической подстановкой параметрического решения.
- **[Python]** Возьмите не менее трёх разных значений t и убедитесь, что $Ax - b$ близко к нулю.
- **[Интерпретация]** Объясните, почему два независимых уравнения не определяют единственную точку в пространстве трёх неизвестных.

7. Проекция

Короткая теория

Проекция $\mathbf{y}$ на пространство столбцов $\mathbf{A}$ — ближайший к $\mathbf{y}$ вектор, который можно представить как $\mathbf{Ax}$:

$$\text{Proj}(\mathbf{y}; \mathbf{A}) = \underset{\mathbf{v} \in \mathcal{R}(\mathbf{A})}{\text{argmin}} \|\mathbf{v} - \mathbf{y}\|_2.$$

Если столбцы $\mathbf{A}$ линейно независимы, то

$$\hat{\mathbf{y}} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{y}.$$

Разность $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ ортогональна пространству столбцов: $\mathbf{A}^T \mathbf{e} = \mathbf{0}$. См. [теорию о проекции, с. 8](#).

Задание 7.1. Проекция на прямую

Пусть

$$\mathbf{y} = (3, 1)^T, \quad \mathbf{a} = (1, 1)^T.$$

- **[Бумара]** Найдите коэффициент $c = (\mathbf{a}^T \mathbf{y}) / (\mathbf{a}^T \mathbf{a})$ и проекцию $\hat{\mathbf{y}} = c\mathbf{a}$.
- **[Markdown]** Найдите остаток $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ и покажите, что $\mathbf{a}^T \mathbf{e} = 0$.
- **[Python]** Проверьте все вычисления и постройте векторы $\mathbf{y}$, $\hat{\mathbf{y}}$ и $\mathbf{e}$ на плоскости.
- **[Интерпретация]** Объясните, почему проекция является лучшим приближением $\mathbf{y}$ точкой на прямой, натянутой на $\mathbf{a}$.

8. Метод наименьших квадратов: первая модель данных

Короткая теория

Добавим к матрице признаков столбец единиц для свободного члена:

$$\mathbf{D} = \begin{pmatrix} 1 & X_{11} & X_{12} \\ \vdots & \vdots & \vdots \\ 1 & X_{81} & X_{82} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}.$$

Предсказания имеют вид $\hat{\mathbf{y}} = \mathbf{D}\boldsymbol{\beta}$. Когда восемь уравнений для трёх коэффициентов нельзя выполнить точно одновременно, выбирают коэффициенты, минимизирующие сумму квадратов ошибок:

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta}}{\text{argmin}} \frac{1}{2} \|\mathbf{D}\boldsymbol{\beta} - \mathbf{y}\|_2^2.$$

Нормальные уравнения имеют вид

$$\mathbf{D}^T \mathbf{D} \hat{\boldsymbol{\beta}} = \mathbf{D}^T \mathbf{y}.$$

В вычислениях используем `numpy.linalg.lstsq`, поскольку явно формировать обратную матрицу не требуется и численно это обычно надёжнее. Теорию см. на [с. 38–39](#).

Задание 8.1. Матричная запись регрессии

- **[Бумара]** Выпишите первую и последнюю строки уравнения $\hat{\mathbf{y}} = \mathbf{D}\boldsymbol{\beta}$ в скалярной форме.
- **[Markdown]** Объясните роли β_0 , β_1 и β_2 , указав единицы изменения итогового балла.
- **[Python]** Постройте $\mathbf{D}$, найдите коэффициенты командой `np.linalg.lstsq(D, y, rcond=None)` и вычислите $\hat{\mathbf{y}}$.
- **[Интерпретация]** Объясните знак каждого коэффициента. Не трактуйте коэффициент как причинный эффект: это описание данного небольшого набора, а не эксперимент.

Задание 8.2. Невязка и качество приближения

- **[Бумага]** Для одного выбранного студента вычислите предсказание по найденной формуле и его остаток $e_i = y_i - \hat{y}_i$.
- **[Markdown]** Запишите определения

$$SSE = \sum_i (y_i - \hat{y}_i)^2, \quad R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}.$$

- **[Python]** Вычислите SSE, RMSE и R^2 , постройте график «наблюдение — предсказание» и график остатков.
- **[Интерпретация]** Объясните, что значит высокое R^2 именно для этих восьми наблюдений и почему оно само по себе не гарантирует хорошее качество на новых данных.

Задание 8.3. Регрессия как проекция

- **[Python]** Проверьте условия

$$\mathbf{D}^T(\mathbf{y} - \hat{\mathbf{y}}) \approx \mathbf{0}, \quad \hat{\mathbf{y}} \in \mathcal{R}(\mathbf{D}).$$

- **[Интерпретация]** Закончите фразу: «Вектор предсказаний является проекцией вектора результатов на пространство, потому что...»

Граница очной части. К этому моменту пройдена единая линия от координат вектора до модели наименьших квадратов. Все незавершённые задания 1–8 нужно закончить дома. Разделы 9 и 10 — обязательное домашнее продолжение, а не отдельная лабораторная.

9. Базовое PCA: новое направление вместо двух признаков

Зачем это нужно

Часы практики и число выполненных комплектов в нашем наборе тесно связаны. PCA ищет ортонормированные направления, вдоль которых стандартизованные данные изменяются сильнее всего. Первое направление позволяет заменить два коррелирующих признака одной координатой, сохранив большую долю вариации.

Перед PCA признаки стандартизируются:

$$Z_{ij} = \frac{X_{ij} - \mu_j}{s_j}.$$

Затем строится ковариационная матрица

$$\mathbf{C} = \frac{1}{n} \mathbf{Z}^T \mathbf{Z},$$

а её собственные векторы задают главные направления:

$$\mathbf{C} \mathbf{u}_k = \lambda_k \mathbf{u}_k.$$

Доля объяснённой дисперсии компоненты равна

$$r_k = \frac{\lambda_k}{\sum_j \lambda_j}.$$

Собственные векторы и геометрию квадратичных форм см. на с. 25–27, стандартизацию и отбеливание — на с. 27–28.




Рис. 7. Собственные векторы задают главные оси эллиптических линий уровня.




Рис. 8. Переход от исходных признаков к стандартизованному и отбеленному представлению.

Задание 9.1. Выполнить готовый алгоритм

В ноутбуке уже дан код, который:

1. центрирует и стандартизирует $\mathbf{X}$;
 2. строит $\mathbf{C}$;
 3. получает собственные значения и векторы командой `np.linalg.eigh`;
 4. сортирует компоненты по убыванию λ_k ;
 5. проектирует данные на первую компоненту;
 6. восстанавливает приближение исходных признаков;
 7. визуализирует исходные и восстановленные точки.
- **[Python]** Выполните готовые ячейки сверху вниз. Самостоятельная реализация PCA не требуется.
 - **[Markdown]** Выпишите размерности $\mathbf{X}$, $\mathbf{Z}$, $\mathbf{C}$, матрицы собственных векторов и одномерных координат.
 - **[Интерпретация]** Ответьте:
 1. какую долю вариации объясняет первая компонента;
 2. почему коэффициенты двух признаков в ней близки по модулю;
 3. какие студенты имеют крайние значения новой координаты;
 4. что потеряно при восстановлении по одной компоненте;
 5. почему одновременная смена знака собственного вектора и всех координат не меняет решения.

Задание 9.2. Польза и ограничения

- **[Интерпретация]** Сформулируйте одним абзацем, когда сжатие двух признаков до одного полезно для визуализации или модели.
- **[Интерпретация]** Укажите не менее двух ограничений: PCA чувствителен к масштабу, описывает линейные направления и не использует целевой вектор y при выборе компонент.

10. Базовое SVD: малоранговое приближение изображения

Зачем это нужно

Для любой матрицы $\mathbf{A} \in \mathbb{R}^{m \times n}$ сингулярное разложение имеет вид

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T.$$

Если оставить только первые k сингулярных чисел и соответствующие столбцы, получится приближение ранга k :

$$\mathbf{A}_k = \mathbf{U}_{:,1:k} \mathbf{S}_{1:k,1:k} \mathbf{V}_{:,1:k}^T.$$

Оно хранит $k(m + n + 1)$ чисел вместо mn . Чем больше k , тем точнее восстановление, но тем меньше выигрыш в объёме. Основы SVD см. на с. 30–31, усечённое SVD и оценку хранения — на с. 33–34.

Задание 10.1. Выполнить готовое SVD

Ноутбук загружает верхнее левое изображение из рис. 9, переводит его в оттенки серого и выполняет `np.linalg.svd`. Для $k \in \{2, 5, 20, 50\}$ готовый код строит восстановление и считает относительную ошибку Фробениуса

$$\varepsilon_k = \frac{\|\mathbf{A} - \mathbf{A}_k\|_F}{\|\mathbf{A}\|_F}.$$

- **[Python]** Выполните готовый код и получите четыре изображения, ошибки и оценки хранения.
- **[Markdown]** Составьте таблицу со столбцами: ранг k , относительная ошибка, количество хранимых чисел, доля от исходного объёма.
- **[Интерпретация]** Опишите, какие структуры появляются уже при $k = 2$, какие детали добавляются при $k = 5$ и $k = 20$, и насколько заметно улучшение при $k = 50$.




Рис. 9. Оригинал и приближения рангов 2, 5 и 20 из теоретического пособия.

- **[Интерпретация]** Проверьте, что ошибка не возрастает с ростом k . Объясните, почему это ожидаемо.

Задание 10.2. Связь PCA и SVD

В ноутбуке дополнительно выполняется SVD стандартизованной матрицы учебной активности Z . Правые сингулярные векторы задают те же направления признаков, что и собственные векторы $Z^T Z$.

- **[Python]** Сравните первый собственный вектор PCA с первой строкой V^T с точностью до знака.
- **[Интерпретация]** Объясните результат без вывода формул: PCA описывает направления вариации данных, а SVD предоставляет удобный общий способ получить эти направления непосредственно из матрицы.

11. Итоговая интерпретация

Задание 11.1. Карта понятий

- **[Markdown]** Напишите связный текст из 8–12 предложений, используя термины: *вектор наблюдения, матрица данных, линейное отображение, ранг, система уравнений, проекция, наименьшие квадраты, главная компонента, сингулярное число, малоранговое приближение*.
- **[Интерпретация]** Для каждого из трёх итоговых результатов — регрессия, PCA, SVD — укажите:
 1. какой объект подаётся на вход;
 2. какой объект получается на выходе;
 3. какую практическую пользу даёт результат;
 4. какая информация при этом может быть потеряна или неправильно истолкована.

Что сдавать

Сдаётся заполненный студенческий ноутбук. Перед отправкой выполните все ячейки сверху вниз и убедитесь, что выводы сохранены.

Чек-лист:

- все задания **[Бумара]** перенесены в Markdown с промежуточными действиями;
- все ячейки **[Python]** выполняются без ошибок;
- размерности матриц указаны и согласованы;
- ответы **[Интерпретация]** относятся к конкретным полученным числам и графикам;
- невязка квадратной системы близка к нулю;
- для регрессии вычислены коэффициенты, остатки, SSE, RMSE и R^2 ;

- для PCA указана объяснённая дисперсия и разобрано восстановление;
- для SVD заполнена таблица рангов 2, 5, 20 и 50, а ошибка не возрастает;
- в последнем разделе дана единая связь между всеми этапами работы.

Справка по синтаксису

В Markdown-ячейке формула внутри строки записывается как $\mathbf{y} = \mathbf{A} \mathbf{x}$, а отдельная формула — между двойными знаками доллара. В NumPy:

<code>A.shape</code>	# размерность массива
<code>A.T</code>	# транспонирование
<code>A @ B</code>	# матричное произведение
<code>np.dot(a, b)</code>	# скалярное произведение
<code>np.linalg.norm(a)</code>	# евклидова норма
<code>np.linalg.det(A)</code>	# определитель
<code>np.linalg.matrix_rank(A)</code>	# ранг
<code>np.linalg.solve(A, b)</code>	# решение квадратной системы
<code>np.linalg.lstsq(A, b, rcond=None)</code>	# наименьшие квадраты
<code>np.linalg.eigh(C)</code>	# спектральное разложение симметричной матрицы
<code>np.linalg.svd(A)</code>	# сингулярное разложение

Все необходимые данные и изображения находятся в проекте; доступ к интернету не требуется.