Вероятность: пошаговая практическая работа

Назначение и результат

Эта часть соединяет события, биномиальную модель, имитацию Монте-Карло и байесовское обновление. Работа начинается с базовых вероятностных задач, последовательно переходит к моделированию и завершается применением идей к данным городского велопроката.

Результат — воспроизводимый ноутбук с формулами, точными вероятностями, имитационной проверкой, графиками Beta-распределений и осторожными выводами. Велопрокат — наблюдательный набор: обнаруженная связь не доказывает причинного влияния погоды на спрос.

Как работать

Для каждого блока сначала заполните Markdown-ячейку «Ответ студента»: назовите случайную величину, событие и допущения; затем запишите формулу, выполните код и интерпретируйте число. Используйте `RANDOM_STATE = 42`; все данные уже локальны, сетевые запросы из ноутбука запрещены.

1. События, объединения и условная вероятность

Обозначения и модель

$P(A)$ — вероятность события A; $\bar{A}$ — событие, противоположное A; $A \cap B$ — одновременное наступление, а $A \cup B$ — наступление хотя бы одного из событий. Если $P(B) > 0$, то

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

События независимы, если знание одного не меняет вероятность другого:

$$P(A \cap B) = P(A)P(B).$$

Без независимости маргинальных вероятностей $P(A)$ и $P(B)$ недостаточно, чтобы восстановить $P(A \cap B)$.

Пусть R — событие «идёт дождь», а D — событие «служба доставки принесла зонт». Известно, что $P(R) = 0.30$ и $P(D) = 0.40$.

Задание 1.1. Совместное событие

Примите **только для этого пункта** независимость R и D. Найдите $P(R \cap D)$ по правилу произведения и явно укажите это допущение.

Задание 1.2. Объединение и дополнение

При том же предположении найдите $P(\bar{R} \cup D)$. Используйте либо формулу объединения, либо дополнение события $R \cap \bar{D}$. Объясните, почему оба пути обязаны дать одно число.

Задание 1.3. Условная вероятность

Теперь независимость не предполагается. Известно $P(D \mid R) = 0.20$. Найдите

$$P(R \cap D) = P(D \mid R)P(R),$$

и сравните результат с заданием 1.1: меняется именно модель зависимости.

2. Биномиальная модель неявок

Обозначения и модель

Если в каждом из n независимых испытаний успех имеет одну и ту же вероятность p, то число успехов X имеет биномиальное распределение:

$$X \sim \text{Binom}(n, p), \qquad P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

В `scipy.stats.binom.sf(k - 1, n, p)` функция выживания (*survival function*) вычисляет $P(X \geq k)$ устойчивее, чем выражение `1 - cdf`.

Задание 2.1. Упражнение о пассажирах

На рейс забронировано $n = 137$ пассажиров. Предположите, что каждый независимо не является с вероятностью $p = 0.40$. Пусть X — число неявившихся пассажиров. Найдите $P(X \geq 50)$ через `scipy.stats.binom.sf`.

Задание 2.2. Проверка имитацией

Смоделируйте $M \geq 100\,000$ значений X и оцените ту же вероятность долей успехов. При $I_i = \mathbf{1}\{X_i \geq 50\}$ оценка имеет вид

$$\widehat{p}_M = \frac{1}{M} \sum_{i=1}^{M} I_i.$$

Симуляция проверяет реализацию точного расчёта, но не доказывает, что допущения о независимости и постоянном p выполняются в реальной кампании.

Задание 2.3. Риск перепродажи мест

Самолёт вмещает $C = 100$ человек; b — число бронирований. Если X — число неявок, отказ в посадке происходит при $b - X > C$. Поскольку X целочисленна,

$$P(b - X > C) = P(X \leq b - C - 1), \qquad X \sim \text{Binom}(b, 0.40).$$

Для всех $b = 100, \ldots, 160$ найдите наибольшее b^*, для которого риск не превышает 5%. Покажите значения для b^* и b^*+1: именно этот соседний переход подтверждает максимум. В выводе перечислите допущения модели.

3. Броски монеты и Beta-обновление

Задание 3.1. Упражнение о 19 бросках

В 19 бросках наблюдались 15 орлов и 4 решки. При честной монете $p = 0.5$ найдите симметричную двустороннюю хвостовую вероятность

$$P(X \leq 4) + P(X \geq 15), \qquad X \sim \text{Binom}(19, 0.5).$$

Это не доказательство нечестности монеты: вычисление показывает совместимость наблюдения с конкретной моделью честной независимой монеты.

Обозначения и модель для байесовского обновления

Априорное распределение (*prior*) $p \sim \text{Beta}(\alpha, \beta)$ задаёт убеждение о вероятности успеха до данных. После s успехов и f неудач апостериорное распределение (*posterior*) равно

$$p \mid \text{данные} \sim \text{Beta}(\alpha + s, \beta + f), \qquad \text{E}[p \mid \text{данные}] = \frac{\alpha + s}{\alpha + \beta + s + f}.$$

Центральный байесовский достоверный интервал (*credible interval*) — диапазон квантилей posterior; его смысл зависит от выбранного prior. Это не частотный доверительный интервал, который описывает повторяемую процедуру выборки.

Задание 3.2. Байесовская версия

Возьмите равномерный prior $\text{Beta}(1, 1)$. После 15 орлов и 4 решек получается $\text{Beta}(16, 5)$. Найдите posterior mean и центральный 95%-й credible interval с `scipy.stats.beta.ppf`, затем постройте обе плотности.

4. Вероятности по данным Bike Sharing

Локальный `hour.csv` содержит 17 379 почасовых наблюдений за 2011–2012 годы. Коды `weathersit=3` и `4` образуют рабочее событие W «неблагоприятная погода»; это не универсальное определение дождя.

Задание 4.1. Операционное определение и таблица событий

На 2011 году один раз зафиксируйте порог высокого спроса как 75-й процентиль `cnt`. На 2012 году создайте H «высокий спрос» и W «неблагоприятная погода», затем оцените $P(H)$, $P(W)$, $P(H \cap W)$, $P(H \mid W)$ и $P(H \mid \bar{W})$. Такое хронологическое разделение не использует 2012 год для настройки порога. Неопределённость самого оценённого порога здесь не моделируется.

Задание 4.2. Независимое приближение

Сравните $P(H \cap W)$ с $P(H)P(W)$. Разность описывает зависимость в этой выборке, но не доказывает влияние погоды: одновременно меняются сезон, час, день недели и другие факторы.

Задание 4.3. Beta-постериоры

Для каждой погодной группы из 2012 года пусть m — число наблюдений, а s — число часов высокого спроса. С prior $\text{Beta}(1, 1)$ примените $\text{Beta}(1+s, 1+m-s)$ к $P(H \mid W)$ и $P(H \mid \bar{W})$. Покажите posterior mean, 95%-е credible intervals и обе плотности.

Что сдать

- заполненный студенческий ноутбук с формулами и ответами в Markdown;
- точный и имитационный расчёты биномиальной вероятности;
- проверку перехода риска между b^* и $b^* + 1$;
- график двух Beta-постериоров и осторожный вывод о данных Bike Sharing.

Самопроверка

- Все вероятности лежат в $[0, 1]$.
- Параметры биномиального распределения — число испытаний и вероятность успеха.
- Условная вероятность определена только при положительной вероятности условия.
- Порог высокого спроса использует только 2011 год; вероятности оцениваются на 2012 году.
- В заключении различены модельные предположения, статистическая связь и причинность.