Описательная статистика и статистический вывод: пошаговая практическая работа

Назначение и результат

Эта часть соединяет описательные статистики, нормальную модель, доверительные интервалы и проверку гипотез с анализом дневного спроса велопроката. Работа последовательно переходит от расчёта статистик к анализу Bike Sharing с явным обсуждением смещения, времени и множественных проверок.

Результат — воспроизводимые расчёты, графики и краткая карточка статистического вывода: вопрос, единица наблюдения, оценка, неопределённость, допущения и границы интерпретации. Статистическая значимость не равна практической важности и не устанавливает причинность.

Как работать

Перед каждым кодовым блоком заполните Markdown-ячейку «Ответ студента»: определите выборку, оцениваемую величину и модель. После вычисления объясните результат и его предпосылки. `ddof=1` используется, когда по выборке оценивается вариабельность неизвестной совокупности.

1. Описательные статистики и нормальная модель

Обозначения и модель

Для значений $x_1, \dots, x_n$ выборочное среднее, выборочная дисперсия и выборочное стандартное отклонение равны

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \qquad s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s = \sqrt{s^2}.$$

Делитель $n-1$ — поправка Бесселя. `np.std(x, ddof=0)` описывает дисперсию переданного конечного набора, а `np.std(x, ddof=1)` вычисляет s.

Задание 1.1. Диаметр филамента

Даны пять измерений диаметра (мм): `1.78`, `1.75`, `1.72`, `1.74`, `1.77`. Найдите $\bar{x}$ и s. Покажите разницу между `ddof=0` и `ddof=1` и объясните, какой вариант используется для оценки изменчивости по выборке.

Задание 1.2. Срок службы смартфона

Предположите, что срок службы T нормально распределён со средним 42 месяца и стандартным отклонением 8 месяцев. Если $F(t) = P(T \le t)$ — функция распределения (CDF), то

$$P(20 \le T \le 30) = F(30) - F(20).$$

Используйте `stats.norm.cdf` и поясните, что результат зависит от нормальной модели, а не только от двух чисел 42 и 8.

2. Интервал и проверка гипотезы

Обозначения и модель

Для уровня значимости α, размера n и выборочного s t-интервал среднего имеет вид

$$\bar{x} \pm t_{1-\alpha/2,n-1}\frac{s}{\sqrt{n}}.$$

Здесь $t_{q,\nu}$ — q-квантиль распределения Стьюдента с ν степенями свободы, а $s/\sqrt{n}$ — стандартная ошибка среднего. Для выборочного s это более обоснованный выбор, чем подстановка нормального критического значения.

Задание 2.1. 99%-й интервал для диаметра

По $n = 34$ измерениям получены $\bar{x} = 1.715588$ и $s = 0.029252$. Постройте 99%-й t-интервал. Укажите, что 99% в частотной интерпретации относится к долгосрочному покрытию процедуры, а не к вероятности фиксированного параметра после наблюдения данных.

Задание 2.2. Маркетинговая кампания

До кампании дневные продажи имели среднее $\mu_0 = 10345$ долларов и известное стабильное стандартное отклонение $\sigma = 552$ долларов. За $n = 45$ дней наблюдалось $\bar{x} = 11641$. Проверьте $H_0 : \mu = \mu_0$ против $H_1 : \mu \neq \mu_0$ с помощью

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}, \qquad p\text{-value} = 2P(Z \geq |z|), \quad Z \sim \mathcal{N}(0,1).$$

Деление на $\sqrt{n}$ обязательно: проверяется среднее 45 дней, а не продажи одного дня. Сообщите z, p-value, решение при $\alpha = 0.05$ и ограничения: независимость дней, неизменность известного σ и отсутствие иных изменений в период кампании.

3. EDA дневного велопроката

Файл `day.csv` содержит 731 запись за 2011–2012 годы. `cnt` — число поездок за день; `season`, `weathersit`, `workingday` и `yr` — кодированные признаки условий и времени.

Задание 3.1. Аудит и графики

Проверьте размер, типы, пропуски и дубликаты. Выведите среднее, медиану, стандартное отклонение, минимум, максимум и квантили `cnt`. Постройте гистограмму, общий boxplot и boxplot спроса по `workingday`.

Задание 3.2. Смещение способа отбора

Полный `day.csv` используется здесь только как учебный известный эталон. Для любой выборки S определите смещение относительно него:

$$\text{bias}(S) = \bar{x}_S - \bar{x}_{\text{day}}.$$

Сравните среднее всех дней с тремя оценками по 90 дням: случайной, первыми 90 днями и случайными 90 летними днями. Объясните, почему две последние выборки не репрезентативны для годового спроса.

4. Интервалы, подтверждение и множественные проверки

Задание 4.1. Два интервала

Для случайной выборки из задания 3.2 постройте 95%-й t-интервал и percentile bootstrap-интервал. Bootstrap (бутстреп) создаёт $B = 10\,000$ выборок с возвращением и использует квантили 0.025 и 0.975 распределения

$$\bar{x}^{*(1)}, \ldots, \bar{x}^{*(B)}.$$

Интервалы описывают среднее процесса сопоставимых дней, а не неизвестное среднее уже полностью наблюдаемой таблицы из 731 дня. Временная зависимость и сезонность ограничивают i.i.d.-интерпретацию обоих методов.

Задание 4.2. Исследование и подтверждение

На 2011 году предварительно оцените разницу среднего `cnt` между рабочими и нерабочими днями. На 2012 году, не меняя вопроса, проверьте $H_0 : \mu_1 - \mu_0 = 0$ двусторонним Welch t-test. Для групп с оценками $(\bar{x}_1, s_1, n_1)$ и $(\bar{x}_0, s_0, n_0)$ используйте

$$t_W = \frac{\bar{x}_1 - \bar{x}_0}{\sqrt{s_1^2/n_1 + s_0^2/n_0}}.$$

Сообщите разность средних, Welch p-value и 95%-й Welch-интервал разности. Welch не требует равенства дисперсий, но не устраняет сезонность, временную зависимость, праздники, погоду и смешение факторов. Следовательно, результат не доказывает причинного эффекта рабочего дня.

Задание 4.3. Ложные находки при множественных проверках

Создайте 100 случайных бинарных групп с `np.random.default_rng(42)` и для каждой выполните Welch t-test различия `cnt`. При верной нулевой модели

$$\mathrm{E}[V] \approx m\alpha = 100 \cdot 0.05 = 5,$$

где V — число p-values ниже α. Наблюдённое число не обязано равняться 5; тесты используют один и тот же отклик и зависимы, но линейность ожидания сохраняет ориентир $m\alpha$. Объясните «ошибку снайпера» — выбор случайно значимого результата после широкого перебора.

Что сдать

- заполненный студенческий ноутбук с формулами и Markdown-интерпретациями;
- таблицу аудита и три графика EDA;
- таблицу сравнения способов отбора и двух интервалов;
- разность средних с Welch-интервалом и p-value;
- итоговый абзац: вопрос, данные, метод, результат, предпосылки и ограничения.

Самопроверка

- В t-интервале стандартная ошибка равна $s/\sqrt{n}$.
- Для z-теста среднего известное σ относится к одному дню, поэтому стандартная ошибка равна $\sigma/\sqrt{n}$.
- 2012 год не используется для выбора подтверждаемой гипотезы.
- Случайные группы не являются реальными факторами спроса.
- Во всех выводах различены статистическая значимость, размер эффекта и причинность.